

# Bayesian Knowledge Tracing (BKT) - Version Complète

D'après Corbett & Anderson (1994, 2005)

29 mars 2026

## Table des matières

|          |                                                   |          |
|----------|---------------------------------------------------|----------|
| <b>1</b> | <b>Introduction</b>                               | <b>3</b> |
| 1.1      | Fondements théoriques . . . . .                   | 3        |
| <b>2</b> | <b>Modèle probabiliste</b>                        | <b>4</b> |
| 2.1      | Définition formelle . . . . .                     | 4        |
| 2.1.1    | État caché . . . . .                              | 4        |
| 2.1.2    | Observation . . . . .                             | 4        |
| 2.2      | Hypothèse d'indépendance conditionnelle . . . . . | 4        |
| <b>3</b> | <b>Les quatre paramètres</b>                      | <b>4</b> |
| 3.1      | 1. Prior : $p_0$ . . . . .                        | 4        |
| 3.2      | 2. Learn (Transition) : $p_T$ . . . . .           | 5        |
| 3.3      | 3. Guess (Devinette) : $p_G$ . . . . .            | 5        |
| 3.4      | 4. Slip (Glissement) : $p_S$ . . . . .            | 5        |
| <b>4</b> | <b>Dynamique du modèle</b>                        | <b>5</b> |
| 4.1      | Transition d'état . . . . .                       | 5        |
| 4.2      | Observation générée . . . . .                     | 6        |
| <b>5</b> | <b>Algorithme EM complet</b>                      | <b>7</b> |
| 5.1      | Vue d'ensemble . . . . .                          | 7        |
| 5.2      | E-STEP : Forward-Backward Pass . . . . .          | 7        |
| 5.2.1    | Forward Pass . . . . .                            | 7        |
| 5.2.2    | Backward Pass . . . . .                           | 8        |

|           |                                             |           |
|-----------|---------------------------------------------|-----------|
| <b>6</b>  | <b>M-STEP : Réestimation des paramètres</b> | <b>8</b>  |
| 6.1       | Expected counts . . . . .                   | 8         |
| 6.2       | Formules de réestimation . . . . .          | 8         |
| 6.3       | Clamping . . . . .                          | 9         |
| <b>7</b>  | <b>Critère de convergence</b>               | <b>9</b>  |
| <b>8</b>  | <b>Pseudocode de l'algorithme</b>           | <b>10</b> |
| 8.1       | Entraînement EM . . . . .                   | 10        |
| 8.2       | Prédiction . . . . .                        | 10        |
| <b>9</b>  | <b>Différences clés</b>                     | <b>11</b> |
| 9.1       | Forward-Backward vs Forward only . . . . .  | 11        |
| <b>10</b> | <b>Considérations pratiques</b>             | <b>11</b> |
| 10.1      | Données . . . . .                           | 11        |
| 10.2      | Initialisation . . . . .                    | 11        |
| 10.3      | Itérations . . . . .                        | 11        |
| 10.4      | Stabilité . . . . .                         | 11        |
| <b>11</b> | <b>Exemple numérique</b>                    | <b>12</b> |
| 11.1      | Forward Pass . . . . .                      | 12        |
| <b>12</b> | <b>Conclusion</b>                           | <b>12</b> |

# 1 Introduction

## 1.1 Fondements théoriques

Ce document présente l’algorithme BKT complet tel que décrit dans les papiers fondateurs :

- **Corbett, K. R., & Anderson, J. R. (1994).** “Knowledge Tracing : Modeling the Acquisition of Procedural Knowledge”
- **Corbett, K. R., & Anderson, J. R. (2005).** “Knowledge Tracing : A Generalized Low-Order Markov Model for Representing Learning”

La principale différence avec les implémentations simplifiées :

- Tous les 4 paramètres ( $p_0, p_T, p_G, p_S$ ) sont estimés
- Utilisation d’un algorithme EM complet avec forward-backward pass
- Inférence probabiliste stricte sur les états cachés

## 2 Modèle probabiliste

### 2.1 Définition formelle

BKT est un **chaîne de Markov cachée** (Hidden Markov Model - HMM) à temps discret.

#### 2.1.1 État caché

L'état de connaissance de l'étudiant à l'étape  $t$  est une variable binaire :

$$L_t \in \{0, 1\}$$

où :

- $L_t = 0$  : L'étudiant ne connaît pas la compétence
- $L_t = 1$  : L'étudiant connaît la compétence

#### 2.1.2 Observation

La réponse observée à l'étape  $t$  est :

$$C_t \in \{0, 1\}$$

où :

- $C_t = 1$  : Réponse correcte
- $C_t = 0$  : Réponse incorrecte

### 2.2 Hypothèse d'indépendance conditionnelle

L'état futur dépend seulement de l'état présent (propriété de Markov) :

$$P(L_{t+1} \mid L_1, L_2, \dots, L_t) = P(L_{t+1} \mid L_t)$$

## 3 Les quatre paramètres

### 3.1 1. Prior : $p_0$

$$p_0 = P(L_0 = 1)$$

**Signification** : Probabilité a priori que l'étudiant connaisse la compétence avant toute tentative.

**Plage typique** :  $[0.1, 0.5]$

### 3.2 2. Learn (Transition) : $p_T$

$$p_T = P(L_{t+1} = 1 \mid L_t = 0)$$

**Signification** : Probabilité que l'étudiant transite de l'état ne connaît pas vers connaît après une tentative.

**Plage typique** :  $[0.1, 0.3]$

### 3.3 3. Guess (Devinette) : $p_G$

$$p_G = P(C_t = 1 \mid L_t = 0)$$

**Signification** : Probabilité d'une réponse correcte malgré l'absence de connaissance.

**Plage typique** :  $[0.05, 0.2]$

### 3.4 4. Slip (Glissement) : $p_S$

$$p_S = P(C_t = 0 \mid L_t = 1)$$

**Signification** : Probabilité d'une réponse incorrecte malgré la connaissance.

**Plage typique** :  $[0.05, 0.2]$

## 4 Dynamique du modèle

### 4.1 Transition d'état

La probabilité de transition entre états :

$$P(L_{t+1} = 1 \mid L_t) = \begin{cases} p_T & \text{si } L_t = 0 \\ 1 & \text{si } L_t = 1 \end{cases}$$

Ou de manière compacte :

$$P(L_{t+1} = 1 \mid L_t) = L_t + (1 - L_t)p_T$$

## 4.2 Observation générée

La probabilité d'observer une réponse donnée l'état :

$$P(C_t = 1 \mid L_t) = \begin{cases} p_G & \text{si } L_t = 0 \\ 1 - p_S & \text{si } L_t = 1 \end{cases}$$

Ou de manière compacte :

$$P(C_t = 1 \mid L_t) = L_t(1 - p_S) + (1 - L_t)p_G$$

## 5 Algorithme EM complet

### 5.1 Vue d'ensemble

L'algorithme EM alterne entre :

1. **E-step** : Calculer distribution a posteriori des états cachés
2. **M-step** : Réestimer les paramètres

### 5.2 E-STEP : Forward-Backward Pass

#### 5.2.1 Forward Pass

Pour chaque étudiant, calculer :

$$\ell_t^{\text{fwd}} = P(L_t = 1 \mid C_{1:t})$$

**Initialisation :**

$$\ell_0^{\text{fwd}} = p_0$$

**Prédiction avant observation :**

$$\ell_t^{\text{pred}} = \ell_{t-1}^{\text{fwd}} + (1 - \ell_{t-1}^{\text{fwd}})p_T$$

**Prédiction de l'observation :**

$$P(C_t = 1 \mid C_{1:t-1}) = \ell_t^{\text{pred}}(1 - p_S) + (1 - \ell_t^{\text{pred}})p_G$$

**Mise à jour si  $C_t = 1$  :**

$$\ell_t^{\text{fwd}} = \frac{(1 - p_S)\ell_t^{\text{pred}}}{\ell_t^{\text{pred}}(1 - p_S) + (1 - \ell_t^{\text{pred}})p_G}$$

**Mise à jour si  $C_t = 0$  :**

$$\ell_t^{\text{fwd}} = \frac{p_S\ell_t^{\text{pred}}}{\ell_t^{\text{pred}}p_S + (1 - \ell_t^{\text{pred}})(1 - p_G)}$$

### 5.2.2 Backward Pass

Calculer la probabilité lissée :

$$\ell_t^{\text{bwd}} = P(L_t = 1 \mid C_{1:T})$$

**Initialisation :**

$$\ell_T^{\text{bwd}} = \ell_T^{\text{fwd}}$$

**Récurrence (pour  $t = T - 1, \dots, 0$ ) :**

$$\ell_t^{\text{bwd}} = \ell_t^{\text{fwd}} \cdot \frac{\ell_{t+1}^{\text{bwd}}}{\ell_t^{\text{pred}}} + (1 - \ell_t^{\text{fwd}}) \cdot \frac{1 - \ell_{t+1}^{\text{bwd}}}{1 - \ell_t^{\text{pred}}}$$

## 6 M-STEP : Réestimation des paramètres

### 6.1 Expected counts

Accumuler pendant E-step :

$$\mathbb{E}[n_{L_t=0}] = \sum_{i,t} (1 - \ell_t^{\text{bwd}})$$

$$\mathbb{E}[n_{L_t=1}] = \sum_{i,t} \ell_t^{\text{bwd}}$$

Observations correctes sans connaissance :

$$\mathbb{E}[n_{C_t=1, L_t=0}] = \sum_{i,t: C_t=1} (1 - \ell_t^{\text{bwd}}) \cdot p_G$$

Observations incorrectes avec connaissance :

$$\mathbb{E}[n_{C_t=0, L_t=1}] = \sum_{i,t: C_t=0} \ell_t^{\text{bwd}} \cdot p_S$$

### 6.2 Formules de réestimation

**Prior :**

$$p_0^{\text{new}} = \frac{1}{N} \sum_{i=1}^N \ell_0^{\text{bwd}, i}$$

**Learn :**

$$p_T^{\text{new}} = \frac{\text{Transitions apprises}}{\mathbb{E}[n_{L_t=0}]}$$

**Guess :**

$$p_G^{\text{new}} = \frac{\mathbb{E}[n_{C_t=1, L_t=0}]}{\mathbb{E}[n_{C_t=1, L_t=0}] + \mathbb{E}[n_{C_t=0, L_t=0}]}$$

**Slip :**

$$p_S^{\text{new}} = \frac{\mathbb{E}[n_{C_t=0, L_t=1}]}{\mathbb{E}[n_{C_t=1, L_t=1}] + \mathbb{E}[n_{C_t=0, L_t=1}]}$$

### 6.3 Clamping

$$p_i^{\text{new}} = \max(\min(p_i^{\text{new}}, 0.99), 0.01)$$

## 7 Critère de convergence

L'algorithme converge quand :

$$\sum_{i \in \{p_0, p_T, p_G, p_S\}} |p_i^{\text{new}} - p_i^{\text{old}}| < 10^{-4}$$

## 8 Pseudocode de l'algorithme

### 8.1 Entraînement EM

Pour chaque compétence  $s$  :

1. Initialiser :  $p_0 = 0.3, p_T = 0.15, p_G = 0.1, p_S = 0.1$
2. Pour chaque itération  $k$  :
  - (a) **E-STEP**
    - Pour chaque étudiant  $i$  :
      - Forward pass : calculer  $\ell_t^{\text{fwd}}$
      - Backward pass : calculer  $\ell_t^{\text{bwd}}$
      - Accumuler expected counts
  - (b) **M-STEP**
    - Réestimer  $p_0, p_T, p_G, p_S$
    - Clamp à  $[0.01, 0.99]$
  - (c) Vérifier convergence
3. Stocker paramètres :  $\text{params}[s] = [p_0, p_T, p_G, p_S]$

### 8.2 Prédiction

Pour chaque (étudiant, compétence) :

1.  $\ell_0 \leftarrow p_0$
2. Pour  $t = 1 \dots T$  :
  - (a)  $\ell_t^{\text{pred}} \leftarrow \ell_{t-1} + (1 - \ell_{t-1})p_T$
  - (b)  $\text{prob} \leftarrow \ell_t^{\text{pred}}(1 - p_S) + (1 - \ell_t^{\text{pred}})p_G$
  - (c) Stocker prédiction
  - (d) Mettre à jour selon  $C_t$

| Aspect       | Forward only | Forward-Backward |
|--------------|--------------|------------------|
| Obs futures  | Non          | Oui              |
| Probabilités | Filtrées     | Lissées          |
| Précision EM | Approx       | Exacte           |
| Complexité   | $O(NT)$      | $O(NT)$          |

## 9 Différences clés

### 9.1 Forward-Backward vs Forward only

## 10 Considérations pratiques

### 10.1 Données

- Triées chronologiquement par étudiant
- Groupées par compétence
- Pas de valeurs manquantes

### 10.2 Initialisation

- $p_0 = 0.3$
- $p_T = 0.15$
- $p_G = 0.1$
- $p_S = 0.1$

### 10.3 Itérations

- Petit dataset : 3-5 itérations
- Dataset moyen : 5-10 itérations
- Grand dataset : 10-20 itérations

### 10.4 Stabilité

- Clamp :  $p_i \in [0.01, 0.99]$
- Epsilon :  $\hat{C}_t = \max(\hat{C}_t, 10^{-10})$

## 11 Exemple numérique

Étudiant avec 5 observations.

Paramètres :  $p_0 = 0.3, p_T = 0.15, p_G = 0.1, p_S = 0.1$

Observations :  $C = [1, 1, 0, 1, 0]$

### 11.1 Forward Pass

$$t = 0 : \quad \ell_0^{\text{fwd}} = 0.3 \quad (1)$$

$$t = 1 : \quad \ell_1^{\text{pred}} = 0.405, \quad \ell_1^{\text{fwd}} = 0.870 \quad (2)$$

$$t = 2 : \quad \ell_2^{\text{pred}} = 0.8895, \quad \ell_2^{\text{fwd}} = 0.985 \quad (3)$$

$$t = 3 : \quad \ell_3^{\text{pred}} = 0.9873, \quad \ell_3^{\text{fwd}} = 0.878 \quad (4)$$

$$t = 4 : \quad \ell_4^{\text{pred}} = 0.878, \quad \ell_4^{\text{fwd}} = 0.51 \quad (5)$$

L'étudiant apprend rapidement (2 bonnes réponses), mais une mauvaise réponse crée de l'incertitude.

## 12 Conclusion

L'algorithme EM complet pour BKT :

1. Estime les 4 paramètres
2. Forward-backward pour raffiner
3. Convergence vers maximum vraisemblance
4. Stable numériquement

Approche rigoureuse des papiers fondateurs.