

Modele de Tracage des Connaissances Base sur les Graphes (GKT)

Fonctionnement et Architecture Complete

Resume Detaille

19 avril 2026

Table des matières

1	Introduction	3
1.1	Contexte et Motivation	3
1.2	Innovation du Modele GKT	3
2	Principes Fondamentaux	3
2.1	Structure du Graphe de Connaissances	3
2.2	Etat Latent et Representation de la Maitrise	3
3	Architecture Complete du Modele GKT	4
3.1	Vue d'Ensemble du Pipeline	4
3.2	Etape 1 : Initialisation des Etats	4
3.3	Etape 2 : Mise a Jour par Interaction	4
3.3.1	Encodage de l'Interaction	4
3.3.2	Mise a Jour Locale du Concept	4
3.3.3	Propagation via Reseaux de Neurons a Graphes	5
3.4	Etape 3 : Prediction	5
4	Exemple Complet de Fonctionnement	5
4.1	Graphe de Concepts	6
4.2	Initialisation	6
4.3	Interaction 1 : L'Etudiant Repond a une Question d'Arithmetique	6
4.4	Interaction 2 : L'Etudiant Repond a une Question de Fractions	6
5	Avantages du Modele GKT	7
6	Limitations et Defis	7
7	Applications Pratiques	7
7.1	Tuteurs Intelligents Adaptatifs	7
7.2	Analyse du Curriculum	7
7.3	Evaluation Automatisee	7
8	Extensions et Variantes	8
8.1	GKT Dynamique	8
8.2	GKT Multi-Modal	8
8.3	GKT Bidirectionnel	8
9	Comparaison avec les Modeles Traditionnels	8

10 Formulation Mathematique Complete	8
10.1 Notation et Cadre Probabiliste	8
10.2 Normalisation du Graphe	9
10.3 Mise a Jour Locale par GRU	9
10.4 Propagation Graphe sur L Couches	9
10.5 Tete de Prediction et Interpretation Probabiliste	9
10.6 Objectif d'Optimisation	9
10.7 Complexite Asymptotique	10
11 Resultats Empiriques	10
12 Implementation Pratique	10
12.1 Frameworks Recommandes	10
12.2 Etapes d'Implementation	10
13 Conclusion	10

1 Introduction

1.1 Contexte et Motivation

Le **tracage des connaissances** (knowledge tracing, KT) est un processus fondamental en apprentissage automatique applique à l'éducation. Il consiste à modéliser l'évolution de la maîtrise d'un étudiant sur des concepts donnés en analysant ses interactions avec un système d'apprentissage intelligent (tuteur intelligent, plateforme en ligne, etc.).

Les modèles traditionnels comme :

- **Bayesian Knowledge Tracing (BKT)** : modèle probabiliste basé sur les chaînes de Markov cachées
- **Deep Knowledge Tracing (DKT)** : approche par réseaux de neurones récurrents (RNN/LSTM)

présentent des limitations importantes. Ils traitent essentiellement des *séquences linéaires* d'interactions étudiantes, sans explicitement modéliser les **relations entre les concepts**.

1.2 Innovation du Modèle GKT

Le modèle **Graph-based Knowledge Tracing (GKT)** apporte une innovation majeure : il représente les relations entre concepts sous forme de **graphe de connaissances** et exploite des **réseaux de neurones à graphes** (Graph Neural Networks, GNN) pour propager l'information à travers cette structure.

2 Principes Fondamentaux

2.1 Structure du Graphe de Connaissances

Le cœur du modèle GKT repose sur une représentation graphique des concepts :

- **Noeuds** : Chaque nœud représente un concept ou une compétence (KnowledgeComponent, KC) en domaine d'apprentissage (p. ex. : addition, fractions, algèbre, etc.)
- **Arêtes** : Les arêtes orientées entre nœuds représentent les relations entre concepts, telles que :
 - Relation de *prerequis* (concept A doit être maîtrisé avant concept B)
 - Relation de *co-requisit* (concepts liés qui doivent être appris ensemble)
 - Relation de *similarité sémantique* (concepts conceptuellement proches)
 - Relation de *transfert de connaissances* (apprendre A facilite l'apprentissage de B)
- **Ponderations d'arêtes** : Chaque arête peut avoir un poids représentant la force de la relation

Construction du graphe :

1. *Approche symbolique* : Utilisation de mappings curriculaires manuels ou de domaines d'experts
2. *Approche data-driven* : Extraction automatique des relations à partir de matrices de similarité ou de corrélations dans les données
3. *Approche hybride* : Combinaison des deux méthodes

2.2 Etat Latent et Représentation de la Maîtrise

Pour chaque concept (nœud), le modèle maintient :

$$\mathbf{h}_{i,t} \in \mathbb{R}^d \tag{1}$$

ou :

- i est l'indice du concept

- t est le pas de temps (apres la t -ieme interaction)
- d est la dimension de l'embedding
- $\mathbf{h}_{i,t}$ est le **vecteur d'etat latent** representant la maitrise du concept i par l'etudiant au temps t

Cet etat latent encode implicitement la probabilite de maitrise du concept et evolue dynamiquement au cours des interactions.

3 Architecture Complete du Modele GKT

3.1 Vue d'Ensemble du Pipeline

Le fonctionnement du modele GKT suit ce pipeline :

1. **Initialisation** : Initialiser les etats latents de tous les concepts
2. **Traitement de l'interaction** : Pour chaque interaction etudiante :
 - (a) Recuperer le concept c_t concerne par la question
 - (b) Encoder la reponse de l'etudiant (correct/incorrect)
 - (c) Mettre a jour l'etat du concept concerne
 - (d) Propager l'information via le graphe a l'aide de GNN
3. **Prediction** : Predire la probabilite de succes pour les questions futures

3.2 Etape 1 : Initialisation des Etats

Au temps $t = 0$, tous les concepts commencent par un etat initial :

$$\mathbf{h}_{i,0} = \mathbf{w}_0 \in \mathbb{R}^d \quad (2)$$

Cet etat peut etre :

- Un vecteur aleatoire appris par le reseau
- Un vecteur uniforme (tous les concepts a etat neutre)
- Un vecteur initialise a partir de connaissances prealables

3.3 Etape 2 : Mise a Jour par Interaction

Supposons qu'a l'instant t , l'etudiant repond a une question portant sur le concept c_t avec une reponse a_t (correcte ou incorrecte).

3.3.1 Encodage de l'Interaction

L'interaction est encodee par :

$$\mathbf{x}_t = \text{Embed}(c_t, a_t) \quad (3)$$

ou Embed est une fonction d'embedding qui combine :

- L'identifiant du concept (one-hot ou embedding)
- L'indicateur de reussite/echec

3.3.2 Mise a Jour Locale du Concept

L'etat du concept implique est d'abord mis a jour localement :

$$\mathbf{h}'_{c_t,t} = \text{Update}(\mathbf{h}_{c_t,t-1}, \mathbf{x}_t) \quad (4)$$

Le module d'update peut etre :

- Une cellule GRU (Gated Recurrent Unit)
 - Une cellule LSTM
 - Un perceptron multicouche (MLP)
- Exemple avec GRU :

$$\mathbf{h}'_{c_t,t} = \text{GRU}(\mathbf{h}_{c_t,t-1}, \mathbf{x}_t) \quad (5)$$

3.3.3 Propagation via Reseaux de Neurons a Graphes

L'etape cruciale du modele GKT est la **propagation de l'information a travers le graphe**. Les concepts lies au concept c_t via des aretes dans le graphe sont affectes indirectement par l'apprentissage de c_t .

Cela simule l'effet de **transfert de connaissances** : maitriser un concept peut faciliter l'apprentissage de concepts lies.

Utilisations courantes de GNN :

Graph Convolutional Network (GCN) Pour chaque concept i et pas de temps t :

$$\mathbf{h}_{i,t}^{(k+1)} = \sigma \left(\sum_{j \in \mathcal{N}(i)} w_{ij} \mathbf{W}^{(k)} \mathbf{h}_{j,t}^{(k)} + \mathbf{b}^{(k)} \right) \quad (6)$$

ou :

- k est la couche GNN
- $\mathcal{N}(i)$ est l'ensemble des voisins du noeud i dans le graphe
- w_{ij} est le poids normalise de l'arete (i,j)
- $\mathbf{W}^{(k)}$ est la matrice de poids apprenable
- σ est une fonction d'activation (ReLU, etc.)

Graph Attention Network (GAT) Une variante qui apprend les poids d'attention :

$$\alpha_{ij} = \text{softmax}_j \left(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]) \right) \quad (7)$$

$$\mathbf{h}_{i,t}^{(k+1)} = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}^{(k)} \mathbf{h}_{j,t}^{(k)} \right) \quad (8)$$

Les coefficients α_{ij} permettent au modele d'apprendre quels voisins sont les plus importants pour chaque concept.

3.4 Etape 3 : Prediction

Apres propagation, les etats latents mis a jour sont utilises pour predire la probabilite de succes :

$$P(\text{succes}_{c,t+1} | \mathbf{h}_{c,t}) = \sigma(\mathbf{W}^T \mathbf{h}_{c,t} + b) \quad (9)$$

ou avec un MLP plus complexe :

$$P(\text{succes}_{c,t+1} | \mathbf{h}_{c,t}) = \sigma(\mathbf{W}_2 \text{ReLU}(\mathbf{W}_1 \mathbf{h}_{c,t} + \mathbf{b}_1) + \mathbf{b}_2) \quad (10)$$

ou σ est la fonction sigmoid assurant que la sortie est dans $[0,1]$.

4 Exemple Complet de Fonctionnement

Considerons un exemple simplifie dans le domaine mathematique.

4.1 Graphe de Concepts

Supposons 4 concepts avec les relations suivantes :

Concept	ID	Description
0	Arithmetique	Operations de base
1	Fractions	Manipulation de fractions
2	Algebre	Resolution d'equations
3	Geometrie	Calcul de surfaces

Relations (Aretes) :

- Arithmetique $\rightarrow$ Fractions (prerequis)
- Arithmetique $\rightarrow$ Algebre (prerequis)
- Fractions $\rightarrow$ Algebre (complementaire)
- Algebre $\leftrightarrow$ Geometrie (concepts lies)

4.2 Initialisation

$$\mathbf{h}_{0,0} = \mathbf{h}_{1,0} = \mathbf{h}_{2,0} = \mathbf{h}_{3,0} = [0, 0, 0, 0]^T \quad (11)$$

Dimension d'embedding : $d = 4$

4.3 Interaction 1 : L'Etudiant Repond a une Question d'Arithmetique

L'etudiant repond **correctement** a une question sur l'Arithmetique.

1. **Encodage** : $\mathbf{x}_1 = [1, 1, 0, 0]^T$ (concept 0, reponse correcte)
2. **Mise a jour locale** :

$$\mathbf{h}'_{0,1} = \text{GRU}(\mathbf{h}_{0,0}, \mathbf{x}_1) \approx [0.3, 0.2, 0.1, 0.05]^T \quad (12)$$

Les autres concepts restent inchanges initialement.

3. **Propagation via GCN** :

Le concept Arithmetique (0) affecte ses voisins Fractions (1) et Algebre (2) :

$$\mathbf{h}_{1,1}^{\text{new}} = \mathbf{h}_{0,0} + \alpha \cdot (\mathbf{W}\mathbf{h}'_{0,1}) \quad (13)$$

$$\approx [0.15, 0.1, 0.05, 0.02]^T \quad (14)$$

$$\mathbf{h}_{2,1}^{\text{new}} = \mathbf{h}_{0,0} + \alpha \cdot (\mathbf{W}\mathbf{h}'_{0,1}) \quad (15)$$

$$\approx [0.15, 0.1, 0.05, 0.02]^T \quad (16)$$

Geometrie (3) n'est pas directement affectee.

4.4 Interaction 2 : L'Etudiant Repond a une Question de Fractions

L'etudiant repond **incorrectement** a une question sur les Fractions.

1. **Encodage** : $\mathbf{x}_2 = [0, 0, 1, 0]^T$ (concept 1, reponse incorrecte)

2. Mise a jour locale :

$$\mathbf{h}'_{1,2} = \text{GRU}(\mathbf{h}_{1,1}, \mathbf{x}_2) \approx [0.1, 0.08, 0.04, 0.01]^T \quad (17)$$

L'etat diminue car la reponse est incorrecte.

3. Propagation via GCN :

Fractions (1) affecte ses voisins Arithmetique (0) et Algebre (2).

L'impact sur l'etat d'Algebre (2) est considere : bien que Fractions soit mal maitrisee, Algebre peut toujours progresser via Arithmetique.

5 Avantages du Modele GKT

- ✓ **Capture les dependances** : Explicitement modelise les relations entre concepts
- ✓ **Transfert de connaissances** : Simule comment maitriser un concept aide a en apprendre d'autres
- ✓ **Interpretabilite** : La structure du graphe est explicite et comprehensible
- ✓ **Generalisation** : Peut generaliser a des concepts non encore vus
- ✓ **Performance** : Surpasse DKT et BKT sur plusieurs datasets
- ✓ **Flexibilite** : Peut integrer differentes architectures GNN

6 Limitations et Defis

- × **Construction du graphe** : Requiert un effort pour creer un graphe precis
- × **Scalabilite** : Peut devenir couteux computationnellement
- × **Qualite des donnees** : Sensible a la qualite du graphe
- × **Overfitting** : Avec peu de donnees, risque de surapprentissage
- × **Parametres du graphe** : Determination des poids des aretes complexe

7 Applications Pratiques

7.1 Tuteurs Intelligents Adaptatifs

Les modeles GKT peuvent alimenter des systemes qui :

1. Evaluent en temps reel la maitrise de chaque concept
2. Recommandent les exercices optimaux bases sur les lacunes
3. Expliquent les difficultES d'apprentissage

7.2 Analyse du Curriculum

1. Validation du graphe d'ordre
2. Detection de gaps d'apprentissage
3. Optimisation pedagogique

7.3 Evaluation Automatisee

Predire le niveau de maitrise global d'un etudiant dans un domaine a partir d'interactions partielles.

8 Extensions et Variantes

8.1 GKT Dynamique

Adapter les poids des aretes pendant l'apprentissage :

$$w_{ij}(t) = w_{ij}(t-1) + \lambda \cdot \Delta w_{ij}(t) \quad (18)$$

Cela permet au modele de decouvrir les vraies relations entre concepts.

8.2 GKT Multi-Modal

Inclure des informations supplementaires :

- Difficulte des questions
- Temps consacre aux taches
- Type d'exercice (QCM, reponse libre, etc.)
- Profil demographique de l'etudiant

8.3 GKT Bidirectionnel

Permettre aux aretes d'etre bidirectionnelles, modelisant les dependances mutuelles entre concepts.

9 Comparaison avec les Modeles Traditionnels

Critere	BKT	DKT	GKT
Modelise relations	Non	Non	Oui
Base sur graphe	Non	Non	Oui
Interpretabilite	Moyen	Faible	Elevee
Performance	Bon	Excellent	Excellent+
Complexite	Basse	Elevee	Elevee
Donnees requises	Moyen	Eleve	Moyen

10 Formulation Mathematique Complete

10.1 Notation et Cadre Probabiliste

On considere une sequence d'interactions d'un etudiant :

$$\mathcal{D} = \{(q_t, c_t, a_t)\}_{t=1}^T \quad (19)$$

ou q_t est la question, $c_t \in \{1, \dots, n\}$ le concept associe, et $a_t \in \{0, 1\}$ la reponse (1 = correcte).

Le graphe de concepts est $G = (V, E)$ avec $|V| = n$ et matrice d'adjacence $\mathbf{A} \in \mathbb{R}^{n \times n}$. L'etat latent global est :

$$\mathbf{H}_t = [\mathbf{h}_{1,t}; \dots; \mathbf{h}_{n,t}] \in \mathbb{R}^{n \times d} \quad (20)$$

avec $\mathbf{h}_{i,t}$ representant la maitrise du concept i au temps t .

Le modele parametre une loi conditionnelle :

$$P(a_t = 1 \mid \mathcal{D}_{<t}, G; \Theta) = \hat{p}_t \quad (21)$$

et l'apprentissage correspond a une estimation du maximum de vraisemblance reguliere.

10.2 Normalisation du Graphe

Pour stabiliser la propagation, on utilise classiquement :

$$\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}, \quad \tilde{\mathbf{D}}_{ii} = \sum_j \tilde{\mathbf{A}}_{ij} \quad (22)$$

et la matrice normalisee symetrique :

$$\mathbf{S} = \tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \quad (23)$$

ce qui evite une explosion numerique sur les noeuds de fort degre.

10.3 Mise a Jour Locale par GRU

L'interaction est encodee par

$$\mathbf{x}_t = \text{Embed}(c_t) \oplus [a_t, 1 - a_t]. \quad (24)$$

Pour le concept observe c_t , une cellule GRU realise :

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{c_t, t-1} + \mathbf{b}_z), \quad (25)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{c_t, t-1} + \mathbf{b}_r), \quad (26)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{c_t, t-1}) + \mathbf{b}_h), \quad (27)$$

$$\mathbf{h}'_{c_t, t} = (1 - \mathbf{z}_t) \odot \mathbf{h}_{c_t, t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (28)$$

Les autres noeuds sont conserves localement avant propagation :

$$\mathbf{h}'_{i, t} = \mathbf{h}_{i, t-1}, \quad i \neq c_t. \quad (29)$$

10.4 Propagation Graphe sur L Couches

En notant $\mathbf{H}'_t$ la matrice apres mise a jour locale, la propagation GCN s'ecrit :

$$\mathbf{H}_t^{(0)} = \mathbf{H}'_t, \quad (30)$$

$$\mathbf{H}_t^{(\ell+1)} = \phi \left(\mathbf{S} \mathbf{H}_t^{(\ell)} \mathbf{W}^{(\ell)} + \mathbf{1}(\mathbf{b}^{(\ell)})^\top \right), \quad \ell = 0, \dots, L-1. \quad (31)$$

La sortie de propagation est $\mathbf{H}_t^{(L)}$. Cette operation couple explicitement les concepts voisins et formalise le transfert de connaissances.

10.5 Tete de Prediction et Interpretation Probabiliste

Pour predire la reponse future sur un concept cible c , on applique :

$$\hat{p}_{c, t+1} = \sigma \left(\mathbf{w}_p^\top \mathbf{h}_{c, t}^{(L)} + b_p \right). \quad (32)$$

Ainsi,

$$a_{t+1} \mid \mathcal{D}_{\leq t}, G \sim \text{Bernoulli}(\hat{p}_{c, t+1}). \quad (33)$$

10.6 Objectif d'Optimisation

Sur un ensemble de M etudiants (sequence m de longueur T_m), on minimise :

$$\mathcal{L}(\Theta) = - \sum_{m=1}^M \sum_{t=1}^{T_m} \left[a_t^{(m)} \log \hat{p}_t^{(m)} + (1 - a_t^{(m)}) \log(1 - \hat{p}_t^{(m)}) \right] + \lambda \|\Theta\|_2^2. \quad (34)$$

La derivee du terme BCE par rapport au logit u_t (avec $\hat{p}_t = \sigma(u_t)$) est :

$$\frac{\partial \mathcal{L}}{\partial u_t} = \hat{p}_t - a_t, \quad (35)$$

ce qui facilite une optimisation stable par backpropagation a travers le temps et le graphe.

10.7 Complexite Asymptotique

Pour un pas de temps, le cout dominant est :

$$\mathcal{O}(Ld|E| + Lnd^2 + d^2) \quad (36)$$

ou L est le nombre de couches GCN, $|E|$ le nombre d'aretes, et d la dimension latente.

La memoire est de l'ordre :

$$\mathcal{O}(nd + |E|) \quad (37)$$

hors stockage des activations intermediaires pour l'apprentissage.

11 Resultats Empiriques

Sur plusieurs datasets publics (EdNet, KDD Cup 2010, etc.), les etudes montrent que GKT atteint :

- **AUC** : 0.80-0.85 (vs 0.75-0.78 pour DKT)
- **Accuracy** : 78-82% (vs 72-75% pour BKT)
- **Temps d'inference** : Comparable ou legerement superieur a DKT

L'amelioration est particulierement notable pour les etudiants avec peu d'interactions (donnees clairessees).

12 Implementation Pratique

12.1 Frameworks Recommandes

- **PyTorch Geometric** : Excellente librairie pour GNN
- **TensorFlow GNN** : Alternative supportee par Google
- **PyTorch + DGL** : Deep Graph Library pour flexibilite maximale

12.2 Etapes d'Implementation

1. Construire la matrice d'adjacence **A** du graphe
2. Normaliser **A** (normalization D-A ou symetrique)
3. Definir les couches GCN/GAT
4. Creer la boucle d'entrainement avec backpropagation
5. Evaluer sur un ensemble de test

13 Conclusion

Le modele **Graph-based Knowledge Tracing (GKT)** represente une avancee significative dans la modelisation du processus d'apprentissage etudiant. En combinant la structure explicite de graphes de concepts avec la puissance des reseaux de neurones a graphes, GKT :

1. Capture les **dependances complexes** entre concepts
2. Fournit des **predictions plus precises** de maitrise
3. Offre une **meilleure interpretabilite** pour les educateurs
4. Simule le **transfert de connaissances** entre domaines connexes

Bien que des defis demeurent (construction du graphe, scalabilite), GKT est prometteur pour la prochaine generation de **systemes d'apprentissage personnalises et adaptatifs**.

Références

- [1] Wu, T., Chen, J., Zhang, Z., Niu, G., Zhang, Y., et Guestrin, C. (2021). *Graph-based Knowledge Tracing : Modeling Student Learning with Concept Prerequisite Graph*. Proceedings of the AAAI Conference on Artificial Intelligence.
- [2] Piech, C., Bassen, J., Huang, J., Gagnauli, S., Sahami, M., Guibas, L. J., et Savarese, S. (2015). *Deep knowledge tracing*. In Advances in Neural Information Processing Systems (pp. 505-513).
- [3] Corbett, A. T., et Anderson, J. R. (1994). *Knowledge tracing : Modeling the acquisition of procedural knowledge*. User modeling and user-adapted interaction, 4(4), 253-278.
- [4] Hamilton, W., Ying, Z., et Leskovec, J. (2017). *Inductive representation learning on large graphs*. In Advances in Neural Information Processing Systems (pp. 1024-1034).